

## 卡尔曼滤波的直觉性思考




## 误差与权重的思想：

卡尔曼滤波在处理 and 融合多源信息时，核心思路是**加权**

经典例子：两个温度计测量房间温度时，信哪个温度计多一点

在这样的思想下，我们想写一个方程，每做一次外推，都要衡量一下这项行动的**不确定度**，以便于融合时分配权重。



杨以明理 李以新 乙

7

## 卡尔曼滤波的直觉性思考




## 误差与权重的思想：

我们通常用**方差**、**协方差矩阵**来描述“**不确定度**”

需要强调的一点是，经典卡尔曼滤波假定误差是服从**零均值高斯分布**的

$$\mathcal{N}(x, \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



杨以明理 李以新 乙

8

## 卡尔曼滤波的直觉性思考



卡尔曼滤波的运行过程可以看作是“**预测**”、“**更新**”的循环

$$\begin{aligned} \dot{x}_k &= A\dot{x}_{k-1} + Bu_{k-1} \\ \text{预测: } P_k^- &= AP_{k-1}A^T + Q \end{aligned}$$



杨以明理 李以新 乙

9

## 卡尔曼滤波的直觉性思考



卡尔曼滤波的运行过程可以看作是“**预测**”、“**更新**”的循环

$$\begin{aligned} K_k &= \frac{P_k^- H^T}{HP_k^- H^T + R} \\ \text{更新: } \dot{x}_k &= \dot{x}_k^- + K_k(z_k - H\dot{x}_k^-) \\ P_k &= (I - K_k H)P_k^- \end{aligned}$$



杨以明理 李以新 乙

10

## 卡尔曼滤波的直觉性思考



## 案例假设

假如，你做了一个可以在树林中行走的小机器人，这个机器人需要准确的知道它自己所处的位置，因为它需要导航。

$$\text{状态: } \vec{x}_k = (\vec{p}, \vec{v})$$

$$\text{协方差: } P_k = \begin{bmatrix} \Sigma_{pp} & \Sigma_{pv} \\ \Sigma_{vp} & \Sigma_{vv} \end{bmatrix}$$



杨以明理 李以新 乙

11

## 卡尔曼滤波的直觉性思考



我们可以建立机器人的**运动模型**

机器人有一个**GPS传感器**，它精确到10米左右，测量间隔为10s。（实际中通常为0.1s）

人为施加**控制量**，例如加大油门，可以产生加速度a，为简化案例，设其为已知量



杨以明理 李以新 乙

12

## 卡尔曼滤波的直觉性思考

在GPS的测量结果尚未到达时，我们需要用运动学方程来预测下一刻机器人的状态量（位置与速度）

$$\begin{aligned} p_k &= p_{k-1} + \Delta t v_{k-1} + \frac{1}{2} a \Delta t^2 \\ v_k &= v_{k-1} + a \Delta t \end{aligned} \quad \text{矩阵} \quad \begin{aligned} \hat{\mathbf{x}}_k &= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \hat{\mathbf{x}}_{k-1} + \begin{bmatrix} \frac{\Delta t^2}{2} \\ \Delta t \end{bmatrix} a \\ &= \mathbf{F}_k \hat{\mathbf{x}}_{k-1} + \mathbf{B}_k \vec{u}_k \end{aligned}$$

$$\text{协方差矩阵: } \hat{\mathbf{x}}_k = \mathbf{F}_k \hat{\mathbf{x}}_{k-1} + \mathbf{B}_k \vec{u}_k \quad \begin{aligned} \text{Cov}(\hat{\mathbf{x}}_k) &= \Sigma_k \\ \text{Cov}(\mathbf{A}\hat{\mathbf{x}}_k) &= \mathbf{A}\Sigma_k\mathbf{A}^T \end{aligned} \quad \mathbf{P}_k = \mathbf{F}_k \mathbf{P}_{k-1} \mathbf{F}_k^T + \mathbf{Q}_k$$

$$\text{这就是之前提到的五大公式其二: } \begin{cases} \dot{\hat{\mathbf{x}}}_k = \mathbf{A}\hat{\mathbf{x}}_{k-1} + \mathbf{B}\mathbf{u}_{k-1} \\ \mathbf{P}_k^- = \mathbf{A}\mathbf{P}_{k-1}\mathbf{A}^T + \mathbf{Q} \end{cases}$$

杨以明理 李以新 2

13

## 卡尔曼滤波的直觉性思考


当GPS的测量值到达时：

$$\begin{aligned} \text{测量值: } \hat{\mu}_{\text{expected}} &= \mathbf{H}_k \hat{\mathbf{x}}_k + v_k \\ \text{协方差矩阵: } \Sigma_{\text{expected}} &= \mathbf{H}_k \mathbf{P}_k \mathbf{H}_k^T + \mathbf{R}_k \end{aligned}$$

基于我们之前的假设：模型噪声和测量噪声服从均值为0的高斯分布

这意味着，我们的估计值和测量值，也都可以看作是服从高斯分布的多维随机变量

现在，我们有了两个对系统状态的估计值。一个由运动学模型预测得出，一个由传感器测量得出。



杨以明理 李以新 2

14


## 卡尔曼滤波的直觉性思考

将本案例中的预测值与测量值，作为二维随机变量大致画在平面图中

光斑越亮的位置，代表可能性越大

两个分布的重叠部分，即两个斑点都很亮的区域，是真实值最可能出现的地方。

求两个概率的重叠部分，其实就做乘法



杨以明理 李以新 2

15

## 卡尔曼滤波的直觉性思考

求重叠即做乘法：

$$\mathcal{N}(x, \mu_0, \sigma_0) \cdot \mathcal{N}(x, \mu_1, \sigma_1) = \mathcal{N}(x, \mu', \sigma')$$

代数运算+归一化：

$$\begin{aligned} \mu' &= \mu_0 + \frac{\sigma_0^2 (\mu_1 - \mu_0)}{\sigma_0^2 + \sigma_1^2} \\ \sigma'^2 &= \sigma_0^2 - \frac{\sigma_0^4}{\sigma_0^2 + \sigma_1^2} \end{aligned}$$

化简：

$$\begin{aligned} \mu' &= \mu_0 + \mathbf{k} (\mu_1 - \mu_0) \\ \sigma'^2 &= \sigma_0^2 - \mathbf{k} \sigma_0^2 \end{aligned} \quad \text{其中: } \mathbf{k} = \frac{\sigma_0^2}{\sigma_0^2 + \sigma_1^2} \text{ 为权重}$$

杨以明理 李以新 2

16

## 卡尔曼滤波的直觉性思考

所以我们在融合模型预测值和传感器测量值时，其实一共只需要右边这三个式子：

$$\begin{cases} \mathbf{k} = \frac{\sigma_0^2}{\sigma_0^2 + \sigma_1^2} & \text{为权重系数} \\ \mu' = \mu_0 + \mathbf{k} (\mu_1 - \mu_0) & \text{为最终估计} \\ \sigma'^2 = \sigma_0^2 - \mathbf{k} \sigma_0^2 & \text{为方差评价} \end{cases}$$

$$\begin{aligned} \text{写成矩阵形式: } \quad \mathbf{K} &= \Sigma_0 (\Sigma_0 + \Sigma_1)^{-1} \\ \vec{\mu}' &= \vec{\mu}_0 + \mathbf{K} (\vec{z}_k - \mathbf{H}_k \vec{\mu}_0) \\ \Sigma' &= \Sigma_0 - \mathbf{K} \Sigma_0 \end{aligned} \quad \xrightarrow{\text{代入协方差矩阵}} \quad \begin{cases} \mathbf{K}' = \mathbf{P}_k \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1} \\ \hat{\mathbf{x}}'_k = \hat{\mathbf{x}}_k + \mathbf{K}' (\vec{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_k) \\ \mathbf{P}'_k = \mathbf{P}_k - \mathbf{K}' \mathbf{H}_k \mathbf{P}_k \end{cases}$$

杨以明理 李以新 2

17

## 卡尔曼滤波的直觉性思考

至此，我们完成了对机器人小车的一次状态估计。

顺便还推导出了经典卡尔曼滤波的五大公式

只要继续迭代下去，就可以获得对系统状态的最优估计

$$\text{模型预测: } \begin{cases} \dot{\hat{\mathbf{x}}}_k = \mathbf{A}\hat{\mathbf{x}}_{k-1} + \mathbf{B}\mathbf{u}_{k-1} \\ \mathbf{P}_k^- = \mathbf{A}\mathbf{P}_{k-1}\mathbf{A}^T + \mathbf{Q} \end{cases}$$

$$\text{加权融合: } \begin{cases} \mathbf{K}' = \mathbf{P}_k \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1} \\ \hat{\mathbf{x}}'_k = \hat{\mathbf{x}}_k + \mathbf{K}' (\vec{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_k) \\ \mathbf{P}'_k = \mathbf{P}_k - \mathbf{K}' \mathbf{H}_k \mathbf{P}_k \end{cases}$$

杨以明理 李以新 2

18


## 卡尔曼滤波的直觉性思考

值得一提的是，所谓的**卡尔曼增益K**，作为融合时的权重系数，反映的是我们对测量值的**信任程度**。

正确使用卡尔曼滤波，需要对**过程噪声**和**测量噪声**的协方差做出较为准确的判断。

在**正确使用**的卡尔曼滤波器中，卡尔曼增益会**不断减小**。这意味着测量值对最终估计所起的作用会越来越小，估计模型会**越来越准确**。

$$\mathbf{K}' = \mathbf{P}_i \mathbf{H}_i^T (\mathbf{H}_i \mathbf{P}_i \mathbf{H}_i^T + \mathbf{R}_i)^{-1}$$



熊以明理 李以新

19



## 3 卡尔曼滤波与最小二乘法

## 卡尔曼滤波与最小二乘法

- 经常有文献会提到，卡尔曼滤波是一种**线性、无偏、且误差方差最小**的随机系统最优估计算法。但从刚才的直觉性理解中，我们似乎没有看到这类性质的清晰体现。我们还需要从**最优估计**的角度去理解卡尔曼滤波。
- 学习卡尔曼滤波估计，要知道最优估计理论里面的相关知识，更要了解最基础最根本的最优估计理论，那就是最小二乘法。

熊以明理 李以新

21

## 卡尔曼滤波与最小二乘法

普通最小二乘法：

在一个线性系统中，系统状态估计方程为：

$$\mathbf{Z} = \mathbf{H}\mathbf{x} + \mathbf{v}$$

设  $\hat{\mathbf{x}}$  为  $\mathbf{x}$  的最优估计，可定义误差为：

$$\mathbf{e} = \mathbf{Z} - \mathbf{H}\hat{\mathbf{x}}$$

定义代价函数：

$$J = e_1^2 + e_2^2 + \dots + e_n^2$$

将代价函数写成向量：

$$\begin{aligned} J &= \mathbf{e}^T \mathbf{e} = (\mathbf{Z} - \mathbf{H}\hat{\mathbf{x}})^T (\mathbf{Z} - \mathbf{H}\hat{\mathbf{x}}) \\ &= \mathbf{Z}^T \mathbf{Z} - \hat{\mathbf{x}}^T \mathbf{H}^T \mathbf{Z} - \mathbf{Z}^T \mathbf{H}\hat{\mathbf{x}} + \hat{\mathbf{x}}^T \mathbf{H}^T \mathbf{H}\hat{\mathbf{x}} \end{aligned}$$

熊以明理 李以新

22

## 卡尔曼滤波与最小二乘法

对矩阵求偏导，令导数为0：

$$\begin{aligned} \frac{\partial J}{\partial \hat{\mathbf{x}}} &= -\mathbf{H}^T \mathbf{Z} - \mathbf{H}^T \mathbf{Z} + (\mathbf{H}^T \mathbf{H} + \mathbf{H}^T \mathbf{H}) \hat{\mathbf{x}} \\ &= -2\mathbf{H}^T \mathbf{Z} + 2\mathbf{H}^T \mathbf{H}\hat{\mathbf{x}} = 0 \end{aligned}$$

解得  $\hat{\mathbf{x}}$  为： $\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{Z}$  即为**普通最小二乘**的估计值

可以看出，估计值是观测值的线性函数，即线性估计

$$\text{估计误差: } \tilde{\mathbf{x}} = \mathbf{x} - \hat{\mathbf{x}} = -(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{v}$$

当测量误差的均值为0时，估计误差的数学期望等于零，**最小二乘估计是无偏估计**

熊以明理 李以新

23

## 卡尔曼滤波与最小二乘法

- 在普通最小二乘中，假设了每一次测量的权重相同，但事实上这样并不合理。假如一个估计值偏离真实值很远，那么它对估计结果的影响就应该被削弱，反之影响应该加强。**加权最小二乘**就是做这样的事。

我们给之前的代价函数增加一个权重矩阵： $J_w(\hat{\mathbf{x}}) = (\mathbf{Z} - \mathbf{H}\hat{\mathbf{x}})^T \mathbf{W} (\mathbf{Z} - \mathbf{H}\hat{\mathbf{x}})$

展开求偏导，如法炮制得：

$$\hat{\mathbf{x}}_{\text{wb}} = (\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} \mathbf{Z}$$

其中  $\mathbf{R}$  为噪声方差阵：

$$\mathbf{R} = E[\mathbf{v}\mathbf{v}^T]$$

熊以明理 李以新

24

卡尔曼滤波与最小二乘法



- 但是，加权最小二乘仍然有问题，就是前面计算出最优估计量后，当有新的数据进来时候，又要重新计算最优估计量。数据量比较大的时候，计算量会变得特别大。
- 所以引出了递推最小二乘，当有新的数据进来，不会再把以前的数据重新计算一遍，而是用当前的观测值对以前的最优估计量进行修正更新。

第k次测量：
$$Z_k = H_k X + v_k$$

假设第k次的最优估计量为前一次最优估计量与测量误差的线性组合：
$$\hat{x}_k = \hat{x}_{k-1} + K_k (Z_k - H_k \hat{x}_{k-1})$$

卡尔曼滤波与最小二乘法



估计误差：
$$\tilde{x} = x_k - \hat{x}_k = x_k - \hat{x}_{k-1} - K_k (Z_k - H_k \hat{x}_{k-1})$$

又由加权最小二乘：
$$\hat{x}_{wls} = (H^T R^{-1} H)^{-1} H^T R^{-1} Z$$

代入估计误差方差阵 $P_k$ ：
$$\begin{aligned} P_k &= Var(\tilde{x}) = E[\tilde{x}\tilde{x}^T] \\ &= E[-(H^T R^{-1} H)^{-1} H^T R^{-1} v] [- (H^T R^{-1} H)^{-1} H^T R^{-1} v]^T \\ &= E[-(H^T R^{-1} H)^{-1} H^T R^{-1} v v^T R^{-1} H (H^T R^{-1} H)^{-1}] \\ &= (H^T R^{-1} H)^{-1} H^T R^{-1} R R^{-1} H (H^T R^{-1} H)^{-1} \\ &= (H^T R^{-1} H)^{-1} H^T R^{-1} H (H^T R^{-1} H)^{-1} \\ &= (H^T R^{-1} H)^{-1} \end{aligned}$$

卡尔曼滤波与最小二乘法



最优估计：
$$\hat{x}_{wls} = P_k H_k^T R_k^{-1} Z_k$$

将 $P_k$ 也写成递推形式：
$$\begin{aligned} P_k &= E[(x_k - \hat{x})(x_k - \hat{x})^T] \\ &= E[x_k - \hat{x}_{k-1} - K_k (Z_k - H_k \hat{x}_{k-1})] \\ &\quad \cdot [x_k - \hat{x}_{k-1} - K_k (Z_k - H_k \hat{x}_{k-1})]^T \\ &= (1 - K_k H_k) P_{k-1} (1 - K_k H_k)^T + K_k R_k K_k^T \end{aligned}$$

代价函数为 $P_k$ 的迹：
$$J = tr(P_k)$$

卡尔曼滤波与最小二乘法



对 $K_k$ 求偏导，令其为0得：
$$K_k = P_{k-1} H_k^T (H_k P_{k-1} H_k^T + R_k)^{-1}$$

代回 $P_k$ ：
$$P_k = P_{k-1} - K_k H_k P_{k-1} = (1 - K_k H_k) P_{k-1}$$

递推最小二乘到此推导完毕，主要方程是如下四个：

$$\left\{ \begin{array}{l} Z_k = H_k X + v_k \\ \hat{x}_k = \hat{x}_{k-1} + K_k (Z_k - H_k \hat{x}_{k-1}) \\ K_k = P_{k-1} H_k^T (H_k P_{k-1} H_k^T + R_k)^{-1} \\ P_k = P_{k-1} - K_k H_k P_{k-1} = (1 - K_k H_k) P_{k-1} \end{array} \right.$$

卡尔曼滤波与最小二乘法



递推最小二乘：

$$\left\{ \begin{array}{l} K_k = P_{k-1} H_k^T (H_k P_{k-1} H_k^T + R_k)^{-1} \\ \hat{x}_k = \hat{x}_{k-1} + K_k (Z_k - H_k \hat{x}_{k-1}) \\ P_k = P_{k-1} - K_k H_k P_{k-1} = (1 - K_k H_k) P_{k-1} \end{array} \right.$$

卡尔曼滤波更新方程组：

$$\left\{ \begin{array}{l} K' = P_k H_k^T (H_k P_k H_k^T + R_k)^{-1} \\ \hat{x}'_k = \hat{x}_k + K' (\vec{z}_k - H_k \hat{x}_k) \\ P'_k = P_k - K' H_k P_k \end{array} \right.$$

两者具有极其相似的形式

卡尔曼滤波与最小二乘法



对比发现，卡尔曼滤波比递推最小二乘法只多了“模型预测”这一部分

而模型预测方程实际就是离散系统的状态空间表达式

我们可以将卡尔曼滤波理解为线性系统的高阶状态空间模型和递推最小二乘的组合应用。因此卡尔曼滤波继承了最小二乘法的一部分特征。

模型预测：
$$\left\{ \begin{array}{l} \hat{x}_k = A \hat{x}_{k-1} + B u_{k-1} \\ P_k = A P_{k-1} A^T + Q \end{array} \right.$$

加权融合：
$$\left\{ \begin{array}{l} K' = P_k H_k^T (H_k P_k H_k^T + R_k)^{-1} \\ \hat{x}'_k = \hat{x}_k + K' (\vec{z}_k - H_k \hat{x}_k) \\ P'_k = P_k - K' H_k P_k \end{array} \right.$$
 (递推最小二乘)



## 4 工程应用实例


### 工程应用实例

#### 在时间同步中的应用

在典型的目标定位任务中，往往涉及测距。

典型测距公式  $\Delta d = c \cdot (T_1 - T_2)$  看似很简单

但由于每个基站都有自己独立的时钟源，每个基站的时钟源所用的晶振都存在不同的频率偏差，况且各基站时钟启动时间不同，在执行定位任务前，必须进行各基站间的时钟同步。



熊以明理 李以新 E


32

### 工程应用实例

我们使用线性模型来描述时钟间的差异。晶振的频率偏差虽然会随温度呈现非线性变化，但在每一个较短的时间内，我们可以认为**线性模型是可靠的**。

模型： $\tau_i(t) = \alpha_i t + \beta_i$

所谓的时钟同步，抽象出来就是建立**相同横坐标下，两条直线上点的映射关系**。




熊以明理 李以新 E

33

### 工程应用实例

我们知道，想建立两条直线的映射关系。至少要知道直线之间的**相对斜率**，以及至少一对点的映射。

由于各基站分布在空间中，具有一定的距离，我们无法在一个时间点同时获得两个基站的本地时间。所以相对斜率，点的映射，都是**无法直接准确测量**。




熊以明理 李以新 E

34

### 工程应用实例

但我们仍然有委曲求全的办法，通过基站间发送**时钟对包**，分别记录本地时间，来获得含有延时的时间测量数据

我们可以使用二维卡尔曼滤波，估计相对斜率，并估计出一对点的映射，实现时间同步



熊以明理 李以新 E

35

### 工程应用实例

预测：

$$\hat{x}_k = A\hat{x}_{k-1} + Bu_{k-1}$$

$$P_k = AP_{k-1}A^T + Q$$

$$\begin{cases} x0 = dt * x1 + x0; \\ x0 = fmod(x0, CLOCK\_PERIOD\_SEC); \\ p0 = (dt * dt * processNoiseVar) * 0.5 + dt * (dt * p3 + p2) \\ \quad + dt * p1 + p0; \\ p\_tmp = ONE\_OVER\_ROOT\_TWO * dt * processNoiseVar \\ \quad + dt * p3; \\ p1 = p\_tmp + p1; \\ p2 = p\_tmp + p2; \\ p3 = processNoiseVar + p3; \end{cases}$$

熊以明理 李以新 E

36

## 工程应用实例

更新:

$$\mathbf{K}' = \mathbf{P}_k \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$\hat{\mathbf{x}}_k' = \hat{\mathbf{x}}_k + \mathbf{K}' (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_k)$$

$$\mathbf{P}_k' = \mathbf{P}_k - \mathbf{K}' \mathbf{H}_k \mathbf{P}_k$$

$$\begin{cases} k0 = p0 / (\text{measNoiseVar} + p0); \\ k1 = p2 / (\text{measNoiseVar} + p0); \\ \\ x0 = k0 * \text{measuredError} + x0; \\ x1 = k1 * \text{measuredError} + x1; \\ \\ p3 = p3 - k1 * p1; \\ p2 = p2 - k1 * p0; \\ p1 = p1 - k0 * p1; \\ p0 = p0 - k0 * p0; \end{cases}$$

杨以明理 李以新

37

## 工程应用实例

设置初值:  $x0 = 0.0; x1 = 1.0;$   
 $p0 = p1 = p2 = p3 = 0.0;$

设置噪声:  $\text{measNoiseVar} = 3e-20;$   
 $\text{processNoiseVar} = 5e-20;$



计数初值:  $\text{counter} = 0;$   
 $\text{outlier\_counter} = 0;$

杨以明理 李以新

38

## 工程应用实例

实际运行情况:

估计斜率 (局部)  
(平均误差 2.599e-09)



估计相对斜率 (整体)

杨以明理 李以新

39

## 工程应用实例

实际运行情况:

估计映射点的误差  
(大时间跨度)

杨以明理 李以新

40



## 5 内容总结

## 内容总结

- 卡尔曼滤波是一种**状态估计算法**，它利用**加权**的思想，**融合**状态空间模型的预测值与传感器的测量值，对系统状态做出**最优估计**。当系统是线性且过程噪声与测量噪声服从高斯分布时，经典卡尔曼滤波有着非常优秀的表现
- 卡尔曼滤波十分强调对“**不确定度**”的判断与量化，这有助于我们分配融合时的**权重**
- 卡尔曼滤波可以看作是**递推最小二乘 (Recursive Least-Square, RLS)**的一类特殊应用，因而也具有递推最小二乘的部分性质，例如：**线性、无偏，且误差方差最小**

杨以明理 李以新

42

